
CONTENTS

—

- ① ~~데이터분석과 기계학습~~
- ② **Linear Regression**
- ③ **Multi-variable
Linear Regression**

02. Linear Regression (선형회귀 개념)

□ 기계학습 예제를 위해 가장 간단한 형태의 데이터를 고려해보자

- 우리반 학생들의 수학 공부시간 대비 시험점수가 아래와 같다. 내가 7시간 공부하면 몇 점 받을 수 있을까?

| 이름 | 수학 공부시간 | 점수 |
|-----|------------|----|
| 야쓰오 | 2 | 3 |
| 오공 | 4 | 4 |
| 블리츠 | 6 | 5 |
| 페이커 | 8 | 6 |

02. Linear Regression (선형회귀 개념)

- 기계학습을 위해 모델링 예제로 바꿔보자
 - 어떻게 모델링을 해야할까?

$X = \text{연습시간 } \{2,4,6,8\}$

입력 x 값에 어떤 **변환**을 하니까 y 가 나온다

$$f(x) = ??$$

$Y = \text{점수 } \{3,4,5,6\}$

02. Linear Regression (선형회귀 개념)

□ 모델링 방법1: 선형회귀

□ 가설: 데이터의 관계를 선형으로 표현할 수 있지 않을까? (예, 공부시간 대비 성적은 비례)


- 종속 변수 y 와 한 개 이상의 독립 변수 x 와의 선형 상관 관계를 모델링하는 회귀분석 기법 (위키)

X = 연습시간 {2,4,6,8}

입력 x 값에 **선형 변환**을 하니까 y 가 나온다

$$f(x) = w * x + b$$


Y = 점수 {3,4,5,6}



02. Linear Regression (선형회귀 개념)

□ 모델링 방법1: 선형회귀

- 관측된 표본 데이터를 가장 잘 설명할 수 있는 선을 하나 찾는다. = 최적화된 w , b 조합을 찾는다.




가능한 w 와 b 조합 중에 어떤 모델이 다른 모델보다 더 좋다고 할 수 있을까?

평가할 척도가 필요하다!!

02. Linear Regression (선형회귀 평가)

□ 선형회귀 평가

- 관측된 표본데이터와 우리가 선택한 w, b 값으로 생성한 직선을 비교해 차이가 적은 w, b 값을 찾자




어떤 평가척도를 사용해서 w, b 를 평가할까?

- 관측된 표본(x_1, y_1)과 f_1 과의 편차 = $(f_1(x_1) - y_1) = 1.2$
- 전체 편차의 합 = $\sum_{i=1} (f_1(x_i) - y_i) = 0$??
- 전체 편차의 평균 = $1/n * \sum_{i=1} (f_1(x_i) - y_i) = 0$??
- 편차 제곱의 평균 = $1/n * \sum_{i=1} (f_1(x_i) - y_i)^2 = 0.8$

02. Linear Regression (선형회귀 평가-MSE)

□ 선형회귀 평가: Mean Squared Error(MSE) == 편차 제곱의 평균 (분산?)

- 과연 편차 제곱의 평균 (MSE)는 w, b 에 따른 차이를 잘 반영할까?



$$cost(W, b) = \frac{1}{m} \sum_{i=1}^m (H(x^{(i)}) - y^{(i)})^2$$

$$f_1(x) = 0.1 * x + 0.4$$

$$x_1, y_1 \rightarrow (f_{\theta_1}(2.0) - 3.0)^2 = ((0.1 * 2.0 + 4.0) - 3.0)^2 = 1.44$$

$$x_2, y_2 \rightarrow (f_{\theta_1}(4.0) - 4.0)^2 = ((0.1 * 4.0 + 4.0) - 4.0)^2 = 0.16$$

$$x_3, y_3 \rightarrow (f_{\theta_1}(6.0) - 5.0)^2 = ((0.1 * 6.0 + 4.0) - 5.0)^2 = 0.16$$

$$x_4, y_4 \rightarrow (f_{\theta_1}(8.0) - 6.0)^2 = ((0.1 * 8.0 + 4.0) - 6.0)^2 = 1.44$$

$$MSE=0.8$$

$$f_2(x) = 0.8 * x + 0.0$$

$$x_1, y_1 \rightarrow (f_{\theta_2}(2.0) - 3.0)^2 = ((0.8 * 2.0 + 0.0) - 3.0)^2 = 1.96$$

$$x_2, y_2 \rightarrow (f_{\theta_2}(4.0) - 4.0)^2 = ((0.8 * 4.0 + 0.0) - 4.0)^2 = 0.64$$

$$x_3, y_3 \rightarrow (f_{\theta_2}(6.0) - 5.0)^2 = ((0.8 * 6.0 + 0.0) - 5.0)^2 = 0.04$$

$$x_4, y_4 \rightarrow (f_{\theta_2}(8.0) - 6.0)^2 = ((0.8 * 8.0 + 0.0) - 6.0)^2 = 0.16$$

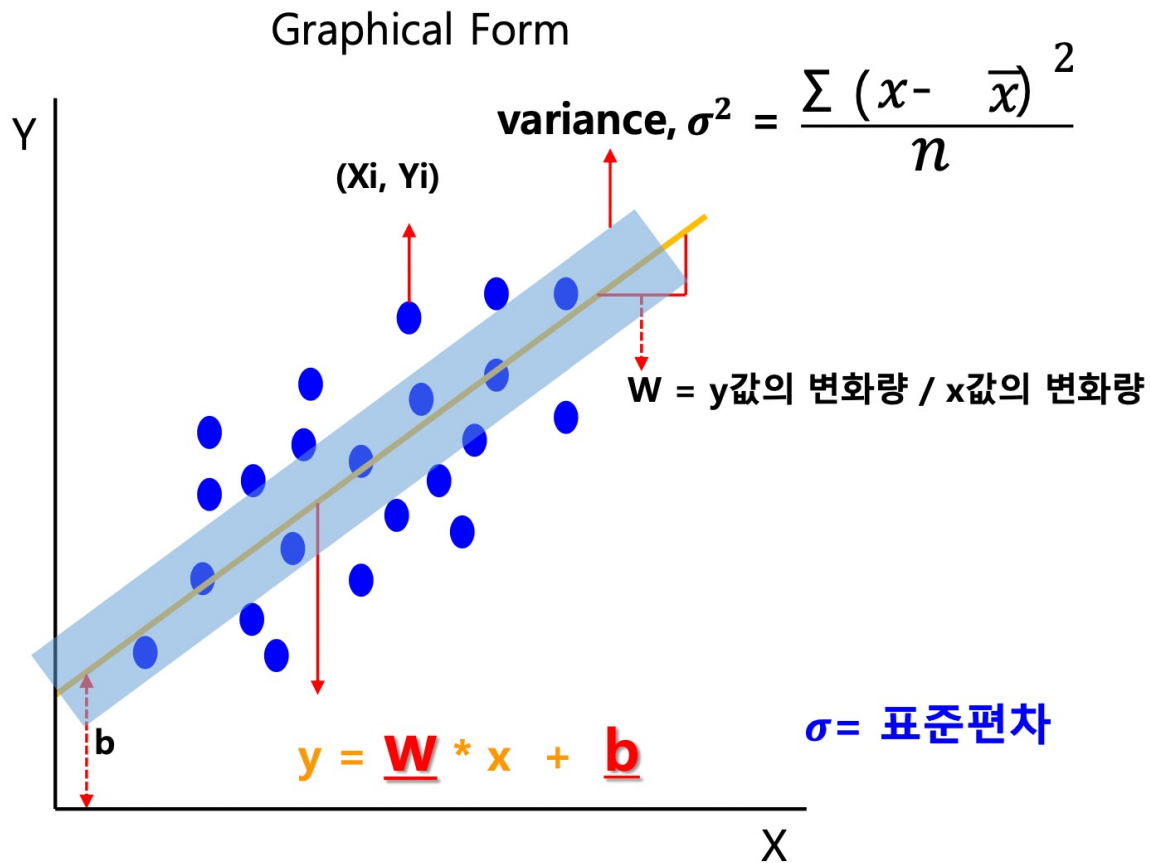
$$MSE=0.7$$

$$f_3(x) = 0.5 * x + 2 \quad MSE=0$$

02. Linear Regression (선형회귀 평가-MSE)

□ 선형회귀 평가: Mean Squared Error(MSE)의 의미

- 분산은 평균을 기준으로 퍼져있는 정도를 나타내는 대푯값.
- 분산이 클 수록 데이터의 분포도가 평균에서 들쭉날쭉 불안정하다, 즉 **오차가 많다**는 의미




우리가 가정(Hypothesis)한 w, b 에
- 오차가 많다 = 손실이 많다
- Cost function = Loss function

$$\text{cost}(W, b) = \frac{1}{m} \sum_{i=1}^m (H(x^{(i)}) - y^{(i)})^2$$

02. Linear Regression (선형회귀 오류 피드백)

□ 최적의 선형회귀란?

- 관측된 표본 데이터를 가장 잘 설명할 수 있는 선을 하나 찾는다. = 최적화된 w, b 조합을 찾는다. = $Cost(w, b)$ 가 최저 값을 보이는 w, b 값을 찾는다.



$Cost(w, b)$ 를 최소화하는 w, b 값을 찾는다.

$$cost(W, b) = \frac{1}{m} \sum_{i=1}^m (H(x^{(i)}) - y^{(i)})^2$$



$$\underset{W, b}{\text{minimize}} \text{cost}(W, b)$$

02. Linear Regression (선형회귀 오류 피드백)

□ Cost(w, b)가 최저 값을 보이는 w, b를 어떻게 찾을까?

- w값의 변화에 의해 Cost(w)값이 어떻게 달라지는지 살펴보자
- cost값이 작아지는 **방향**으로 조금씩 w값을 업데이트 하자!!

$$\text{cost}(W, b) = \frac{1}{m} \sum_{i=1}^m (H(x^{(i)}) - y^{(i)})^2$$
$$\underset{W, b}{\text{minimize}} \text{cost}(W, b)$$




02. Linear Regression (선형회귀 오류 피드백)

- Cost 값이 작아지는 방향은 어떻게 찾을까?
 - 바로 미분! = 기울기

$$\underset{W, b}{\text{minimize}} \text{cost}(W, b)$$


$$\text{cost}(W) = \frac{1}{m} \sum_{i=1}^m (Wx^{(i)} - y^{(i)})^2$$

$$\frac{1}{2m} \sum_{i=1}^m (Wx^{(i)} - y^{(i)})^2$$



02. Linear Regression (선형회귀 오류 피드백)

- Cost 값이 작아지는 방향은 어떻게 찾을까?
 - 바로 미분! = 기울기



$$\underset{W, b}{\text{minimize}} \text{cost}(W, b)$$

$$\text{cost}(W) = \frac{1}{m} \sum_{i=1}^m (Wx^{(i)} - y^{(i)})^2$$

$$\frac{1}{2m} \sum_{i=1}^m (Wx^{(i)} - y^{(i)})^2$$

$$\frac{\partial}{\partial W} \text{cost}(W) = \frac{\partial}{\partial W} \frac{1}{2m} \sum_{i=1}^m (Wx^{(i)} - y^{(i)})^2$$

$$\frac{1}{2m} \sum_{i=1}^m 2(Wx^{(i)} - y^{(i)})x^{(i)}$$

$$\frac{1}{m} \sum_{i=1}^m (Wx^{(i)} - y^{(i)})x^{(i)}$$



02. Linear Regression (선형회귀 오류 피드백)

□ Gradient Descent Algorithm

$$\underset{W, b}{\text{minimize}} \text{cost}(W, b)$$

- 미분을 이용해 cost값이 작아지는 방향으로 조금씩 w값을 업데이트 하자!!

$$W := W - \alpha \frac{\partial}{\partial W} \text{cost}(W)$$




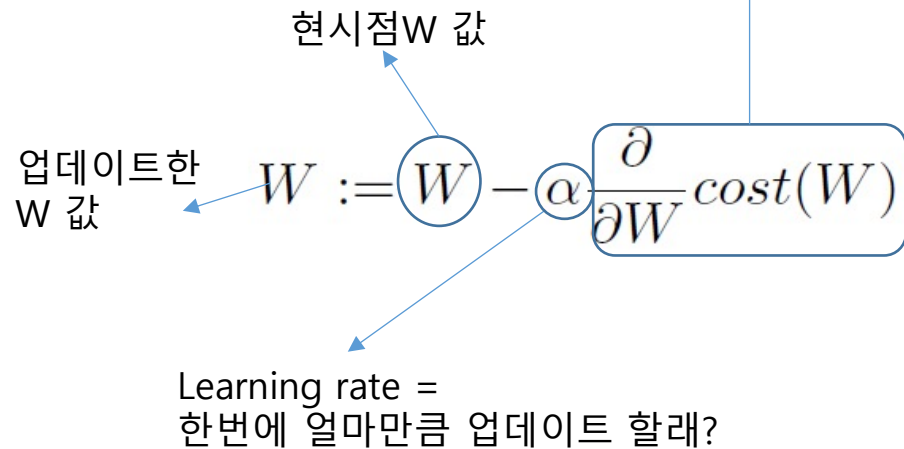
02. Linear Regression (선형회귀 오류 피드백)

□ Gradient Descent Algorithm

- 미분을 이용해 cost값이 작아지는 방향으로 조금씩 w값을 업데이트 하자!!

$$cost(W, b) = \frac{1}{m} \sum_{i=1}^m (H(x^{(i)}) - y^{(i)})^2$$
$$\underset{W, b}{\text{minimize}} \text{cost}(W, b)$$


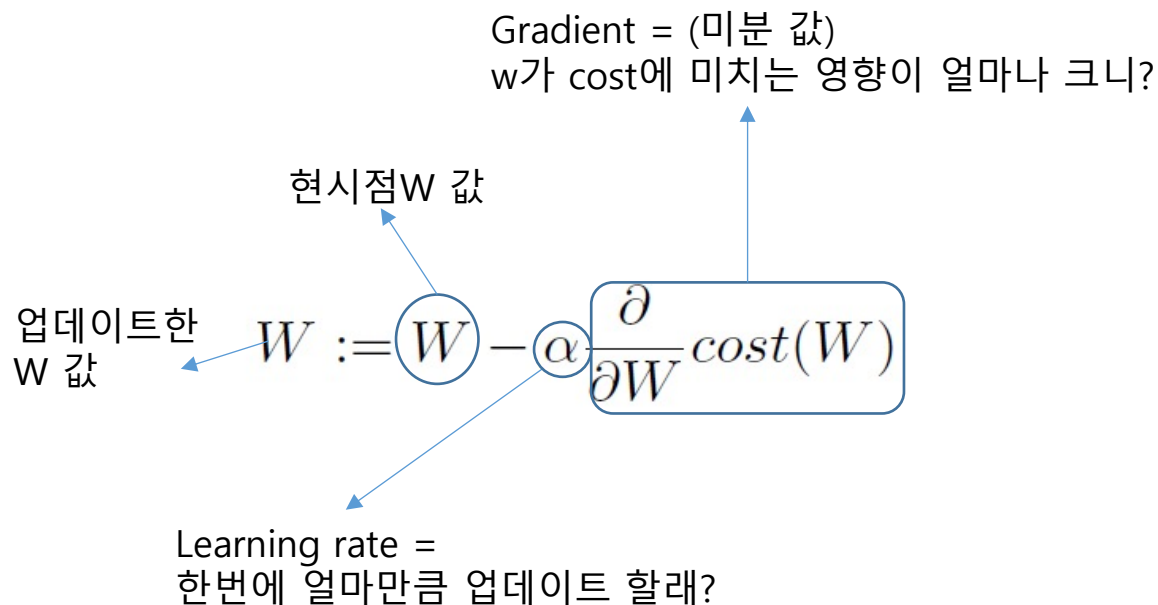
Gradient = 기울기 (미분 값):
w가 cost에 미치는 영향이 얼마나 크니?



02. Linear Regression (선형회귀 오류 피드백)

□ Gradient Descent Algorithm


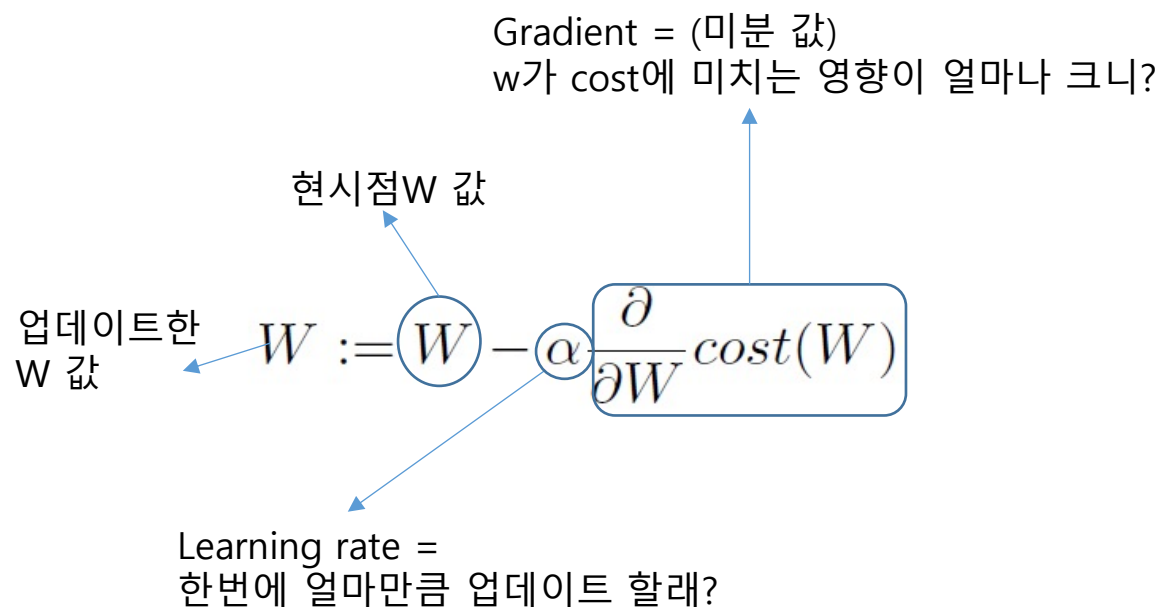
- cost값이 작아지는 방향으로 조금씩 **w, b**값을 업데이트 하자!!



02. Linear Regression (선형회귀 오류 피드백)

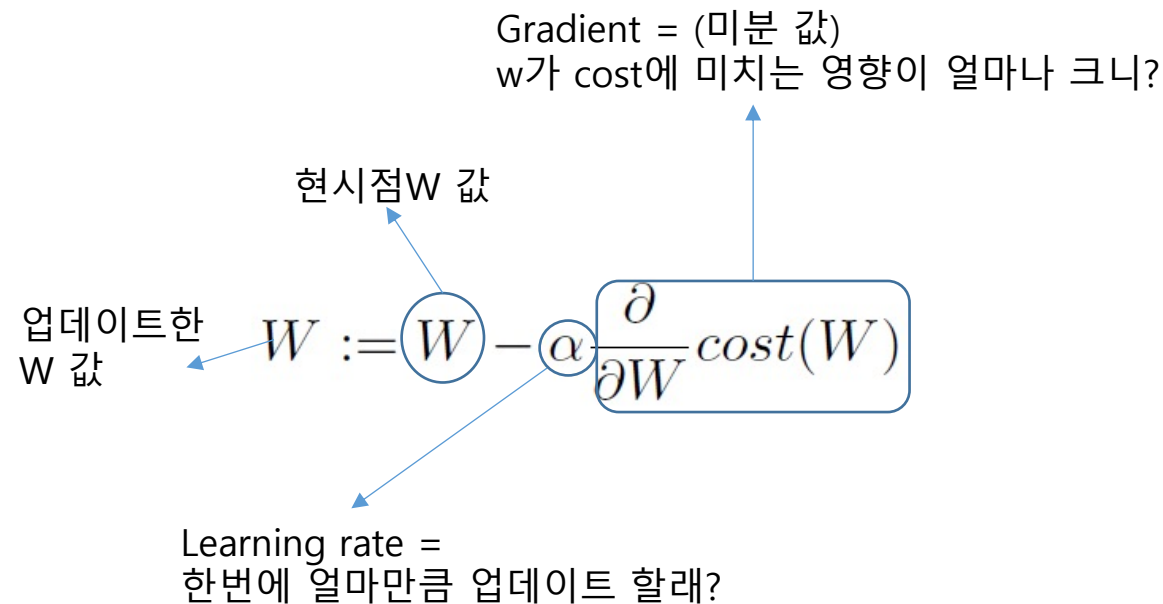
□ Gradient Descent Algorithm

- cost값이 작아지는 방향으로 조금씩 **w, b**값을 업데이트 하자!!



02. Linear Regression (선형회귀 정리)

□ Gradient Descent Algorithm 정리



| | |
|--|----------------------|
| 1. 가설에 따라 W(weight)을 설정하고 x를 넣어 예측 결과물을 얻는다. | Prediction |
| 2. 가설에 따른 결과와 실제 값과의 차이를 계산한다. | Cost Function |
| 3. 가설과 실제 값의 차이(에러)가 어떤 값(w)에서 비롯되었는가? | Differentiation (미분) |
| 4. 역으로 내려가면서 추정하여 w의 가중치를 계산한다. | Back Propagation |
| 5. 추정된 가중치*learning rate 만큼 w 값을 변화시킨다. | Weight Update |



감사합니다.